




Fine-tuning BERT para Classificação de Sentimento Financeiro

Demonstração do processo de fine-tuning de um modelo BERT pré-treinado para classificar sentimento em textos financeiros — notícias, relatórios e análises de mercado.

DEEP LEARNING · NLP · TRANSFER LEARNING


Contexto e Motivação

O Problema

Classificar automaticamente o **sentimento** em textos do domínio financeiro é uma tarefa complexa: linguagem técnica, nuances sutis e vocabulário específico tornam abordagens genéricas insuficientes.

Por que BERT?

- Pré-treinado em grandes corpora multilíngues
- Captura contexto bidirecional com atenção
- Estado da arte em tarefas de NLP
- Transfer Learning: adapta-se ao domínio financeiro com poucos dados




Dataset: Financial Sentiment

Visão Geral

Dataset **lwr42/financial-sentiment-dataset** disponível no Hugging Face Hub, com **90.135 exemplos** rotulados. O dataset original possuía 9 classes; foram mantidas as 5 principais para maior clareza de distinção semântica.

⚠ Dataset **desbalanceado**: classe "positive" representa 38% dos dados, enquanto "moderately negative" corresponde a apenas 3%.



Divisão dos Dados e Arquitetura do Modelo

Conjuntos de Dados

Conjunto	Quantidade	%
Treino	68.973	76,5%
Validação	8.990	10,0%
Teste	12.172	13,5%
Total	90.135	100%


Modelo Base

nlptown/bert-base-multilingual-uncased-sentiment
BERT Base Multilingual · ~110M parâmetros · 6 idiomas (PT, EN, DE, FR, IT, ES). Camada de classificação adaptada para **5 classes**.

Hiperparâmetros de Fine-tuning

Parâmetro	Valor
Learning Rate	2e-5
Batch Size	16
Épocas	1
Weight Decay	0.01
Max Length (tokens)	128
Avaliação	Por época

Pipeline de Processamento



O pipeline é **end-to-end e reprodutível**: do carregamento do dataset até o checkpoint final, cada etapa é documentada. As métricas são calculadas **antes e depois** do fine-tuning para comparação rigorosa.


Desequilíbrio de Classes: Um Desafio Real


O pipeline atual **não implementa** técnicas de balanceamento. O único ajuste é o uso de `average='weighted'` no cálculo das métricas — o que afeta apenas a *avaliação*, não o *treinamento*.

⊗ O modelo tende a privilegiar a classe **positive** (38%), com risco de recall baixo para **moderately negative** (3%).

Sugestões de Balanceamento


- **Class Weights** no Trainer
- **Weighted Loss / Focal Loss**
- **Oversampling** (SMOTE) das classes minoritárias





Resultados: Antes vs. Depois do Fine-tuning

■ Antes (Baseline) ■ Depois (Fine-tuned)



O baseline (~32%) é próximo ao acaso para 5 classes (20%). Após apenas **1 época** de fine-tuning, todas as métricas saltam para **87,3%** — um resultado excepcional que confirma o poder do Transfer Learning no domínio financeiro.

Impacto do Fine-tuning

+176%

Accuracy

De 31,6% para 87,3%

+196%

F1-Score

De 29,4% para 87,3%

~3x

Melhoria Geral

Em todas as 4 métricas avaliadas

0.873

Score Final

Accuracy, Precision, Recall e F1 alinhados

- ✓ Todas as métricas superam o limiar de **85%**, classificado como desempenho excelente para uma tarefa de 5 classes com dataset desbalanceado.

Conclusões e Pontos de Atenção

✅ Pontos Positivos

- Fine-tuning bem-sucedido com **acurácia de 87,3%**
- Pipeline completo, documentado e reprodutível
- Transfer Learning eficaz mesmo com 1 época
- F1 ponderado equilibra o impacto do desbalanceamento

⚠️ Limitações

- Desequilíbrio de classes **não tratado** no treinamento
- Apenas 1 época (fins acadêmicos; mais épocas tendem a melhorar)
- Treinamento em CPU — GPU aceleraria o processo

🔭 Trabalhos Futuros

Class Weights & Focal Loss

Penalizar mais erros em classes minoritárias durante o treino

Mais Épocas + Tuning

Busca de hiperparâmetros (lr, batch size, épocas)

Modelos Alternativos

Ensemble com RoBERTa, DeBERTa ou FinBERT



Obrigado!

Fine-tuning BERT para Sentimento Financeiro
Disciplina: Deep Learning na Prática – Transformers

Dataset

lwr42/financial-sentiment-dataset

Modelo Base

nlptown/bert-base-multilingual-uncased-sentiment

Referência

Devlin et al., 2018 · Hugging Face Transformers